

강화학습을 활용한 Mini Slay the Spire 전투 에이전트 최적화

Random vs Q-Learning vs DQN 성능 비교 및 행동 패턴 분석

A73003 김광서

<https://github.com/pangssseo/mini-slay-the-spire-RL-project>


1. 프로젝트 주제 및 목표

□ 프로젝트 개요

로그라이크 텍빌딩 게임 'Slay the Spire'의 턴제 전투 시스템을
단수화한 커스텀 환경(Mini Nibbit 환경)을 구축하여 강화학습
에이전트를 학습시키고 최적의 전투 정책을 도출합니다.

□ 핵심 목표

- Random / Q-Learning / DQN 간의 성능을 비교 분석
- 복잡한 상태(적의 패턴, 디버프, 체력 등)이 주어졌을 때, 에이전트가
단기적 피해 뿐만 아니라 장기적 생존과 콤보를 고려한 의사결정을 내리는가



2. 환경 및 난이도 설정

□ 전투 규칙

플레이어는 매 턴 에너지 3을 받고 카드를 순서대로 사용한다.

End Turn을 선택하면 Nibbit의 행동이 실행되고 다음 턴으로 넘어간다.

플레이어의 목표는 적(Nibbit)의 HP를 0 이하로 만들면 승리한다.

- Nibbit 행동 패턴

1턴: 12 피해 공격

2턴: 6 피해 공격 + 방어도 5 획득

3턴: 힘 2 획득(이후 공격력 증가)

다시 1턴 패턴 반복

턴이 길어질 수록 플레이어의 생존 확률이 떨어지는 구조

□ 난이도 설정

Mode	Player HP	Enemy HP (Nibbit)
Easy	80	46
Normal	64(-16)	46
Hard	64	48(+2)

Hard mode는 플레이어 생존성 감소와 적 체력 증가로
가장 긴 전투와 정확한 행동 선택이 요구

3. State, Action, Reward 설계

State (상태)

플레이어 : HP, 에너지

적 상태 : HP, 방어도, 힘, 취약

적 의도 : 공격/방어/힘 증가

덱 상태 : 손패/드로우/버린 카드 수

Action (행동)

0 (Strike): 비용 1, 피해 6

1 (Defend): 비용 1, 방어 5

2 (Bash): 비용 2, 피해 8 + 취약 2턴

3 (End Turn): 턴 종료

Reward (보상)

+ 피해량 : 적에게 준 damage

- 피해량 : 받은 damage

승리/패배 : +100 / -100

잘못된 행동 : -5

* 취약 디버는 별도 보상 없이
증가한 피해량으로 reward 반영

4. 강화학습 알고리즘 비교 설계

□ 동일 환경에서 세 가지 정책을 비교

- Random(Baseline)

학습 없이 무작위로 카드를 내는 기준 모델

- Q-Learning

state-action value를 Q-table에 업데이트하여 학습하는 모델



(3,000 episode 학습)

- DQN (Deep Q-Network)

연속적인 state vector를 Neural Network의 입력으로 받아

Q-value를 근사하는 딥러닝 기반 모델

(1,500 episode 학습)



5. 실험 결과 및 성능 분석

난이도별 승률, 보상, 남은 체력 및 에이전트 행동 패턴 추적

5-1. 실험 평가 지표 및 전체 성능 요약표

Metric	지표
Win_rate	전투 승리 비율
Mean_reward	피해량, 생존, 승패 보상 평균
Mean_remaining_hp	전투 종료 시 안정성
Mean_turns	전투 종료까지 턴 수
Action_timeline	Turn별 행동 sequence와 HP변화

<실험 평가 지표>

Mode	Agent	Win(%)	Reward	RemainHP	Turns
Easy	Random	59.0	-4.4	19.4	10.25
	Q-Learning	100.0	135.2	65.5	3.89
	DQN	100.0	134.1	65.1	3.30
Normal	Random	46.5	-25.8	10.8	9.54
	Q-Learning	100.0	134.2	49.0	3.58
	DQN	100.0	135.5	51.0	3.56
Hard	Random	44.5	-28.5	10.5	9.49
	Q-Learning	100.0	135.2	49.5	3.65
	DQN	100.0	140.0	50.7	3.65



<전체 성능 요약표>

5-2. Hard 모드 상세 지표 (보상 및 안정성)

Random
-28.5
(Mean Reward)
Remaining HP 10.5



Q-Learning
135.2
(Mean Reward)
Remaining HP 49.5

DQN
140.0
(Mean Reward)
Remaining HP 50.7



가장 어려운 Hard 조건에서 DQN은 평균 보상 140.0, 남은 HP 50.7로 가장 높은 안정성을 보였다.



5-3. Random Baseline 분석



Random은 학습이 없으므로 episode가 증가해도 reward가 개선되지 않는다.



Hard trace에서는 전투가 11턴까지 길어지고, Nibbit의 힘 누적 이후 큰 피해를 받으며 패배했다.

5-4. 학습 곡선 추이 (Training Curves)



초기 exploration 구간에서는 reward가 흔들릴 수 있지만, 학습 기반 에이전트는 반복 학습 후 높은 reward 영역에 수렴하는 경향을 보였다.

5-5. 에이전트 행동 패턴 분석 (Action Timeline)



Q-Learning은 hard 예시에서 초반 직접 타격을 우선하여 3턴 안에 처치했다.

DQN은 첫 턴부터 Bash로 취약을 부여하고, 2턴에 Defend를 포함하여 피해를 1로 줄였다.

평균 수치 기준으로 DQN은 hard mode에서 Q-Learning보다 reward와 남은 HP가 높았다.

5-6. Episode 수 변경에 따른 성능 비교

Agent	Episodes	Mean Reward	Win Rate	Remain HP
Q-Learning	100	133.84	1.00	49.42
	3,000	135.23	1.00	49.54
DQN	100	136.45	1.00	48.30
	1,500	140.50	1.00	51.29

Episode 수 변경 실험 결과, Q-Learning은 적은 학습량으로도 빠르게 수렴하는 경향을 보였고,

DQN은 더 많은 episode를 통해 피해를 줄이는 안정적인 정책으로 개선되는 경향을 보였다.

따라서 본 프로젝트에서는 DQN의 학습 episode 수 증가가 정책 안정성 향상에 가장 직접적인 영향을 주는 하이퍼파라미터로 확인되었다.

5-7. Q-Learning과 DQN의 차이 분석

Q-Learning: 직접 공격형

Q-table 기반으로 이산화된 state-action value를 학습

Hard 대표 trace: Strike → Strike → Strike → End Turn

3턴 종료로 빠른 처치에는 성공했지만 state 단순화 의존성이 존재

DQN: 방어 및 콤보 연계형

Neural network로 복잡한 state vector를 직접 활용

Hard 대표 trace: Bash → Strike → Defend 연계

Hard mode에서 평균 reward와 남은 HP가 가장 높음

따라서 Q-Learning은 해석이 쉬운 강한 baseline, DQN은 복잡한 상태 정보를 활용하는 확장형 알고리즘으로 설명할 수 있다.

6. 실험 결과 및 개선사항

실험 결과

MDP 환경에서 RL모델들이 모두 좋은 성능을 보였습니다.
특히 DQN은 취약(디버프) 콤보와 방어를 결합하여 가장 높은
안정성과 보상을 확보하는 것을 확인할 수 있었습니다.

보완 및 개선사항

Slay the Spire2의 전체 게임 구조 일부를 단순화한 환경으로
포함되지 못한 요소들을 복합적으로 고려하여 단일 전투를 넘어
장기적인 텍빌딩을 추가가 필요합니다.
또한, 단순한 공격 패턴의 낮은 난이도로 인해
DQN과 Q-Learning의 큰 차이를 보기 어려웠습니다.